

# Spec-Driven Development

---

Nikolas Lacerda Santos

# Contexto

---

- Benchmark de modelos no contexto de SLM

# Metodologia

---

- Github Spec-Kit
- VSCode
- Claude Sonnet 5

# /speckit.constitution

---

- Definidos os princípios que devem orientar o código
- Claude Sonnet para auxílio na criação do prompt
  - Projeto Angular versão 20 com TypeScript.
  - Use standalone components e o padrão de pastas existente em src/app.
  - Siga os services e interceptors HTTP já existentes; não crie novas libs sem justificar.
  - Use SCSS para UI.
  - Formulários com Reactive Forms.
  - Testes unitários para componentes e services.
  - Respeite o lint e o estilo de código já configurados.

# /speckit.specify

---

- Descrição da Tarefa
- Claude Sonnet para auxílio na criação do prompt
- /speckit.specify Quero uma página nova de benchmark de modelos LLM, separada do fluxo principal de conversa com o assistente, onde o usuário possa configurar e executar uma bateria de testes comparando múltiplos modelos...

# /speckit.clarify

---

- Modelo fez 3 esclarecimentos
  - *Similarity score*
  - *LLM models and test questions limit*
  - *Vector database size*
- *Remaining gaps (e.g., data-privacy handling of exported patient-document content) are lower-impact and already covered implicitly by the existing local-only architecture assumption, so I'll stop questioning here.*

# /speckit.plan

---

- Claude Sonnet utilizado para auxiliar no plano
- Restrições técnicas, stack e decisões arquiteturais relevantes

# /speckit.tasks

---

- 55 tarefas criadas

# /speckit.analyze

---

- Dois ciclos de alterações:
  - Primeiro ciclo:
    - *Ambiguity Count: 1*
    - *Duplication Count: 0*
    - *Critical Issues Count: 2*
  - Segundo ciclo:
    - *Ambiguity Count: 1*
    - *Duplication Count: 0*
    - *Critical Issues Count: 0*
  - Terceiro ciclo:
    - *Coverage %: 100%*

# /speckit.implement

---

- Foi executado o *implement* após executar o *analyze* sem issues


# /speckit.converge

---

- Retornou apenas questões de nomenclatura
  - *Rename display labels to reflect the real model families (e.g., "Phi-3.5 mini", "Gemma 2 (2B)")*

# Resultado

---



# Resultado

Chat **Benchmark**



## Benchmark de Modelos LLM

Compare modelos LLM contra um conjunto de perguntas de teste

### ⚙️ Configuração do Benchmark

#### Modelos LLM

- ☒ Llama 3.2 3B (1.5GB)
- ☐ Phi-4-mini
- ☐ Google Gemma 4
- ☐ Qwen3-8B

#### Chunk size

500

#### Tamanho máximo do banco vetorial (nº de chunks)

500

#### Arquivo de entrada (PDF)

[Escolher arquivo](#) Nenhum arquivo escolhido

#### Modelo de embeddings

Xenova/all-MiniLM-L6-v2

Modelo fixo — trocar de modelo de embeddings invalidaria a base vetorial existente.

#### Threshold de similaridade (%)

70

#### Perguntas de teste

Pergunta

Resposta esperada


+ Adicionar pergunta

▶ Executar Benchmark

# Resultado

## Executando...

Modelo atual: Llama-3.2-3B-Instruct-q4f16\_1-MLC — Pergunta: ad588457-4607-4284-9588-156d6021e7e4



## Resultados

Exportar CSV

| Modelo                            | Pergunta                             | Resposta Gerada                                                        | Similaridade | Veredito                       |
|-----------------------------------|--------------------------------------|------------------------------------------------------------------------|--------------|--------------------------------|
| Llama-3.2-3B-Instruct-q4f16_1-MLC | ad588457-4607-4284-9588-156d6021e7e4 | A finalidade do Tacrolimo é prevenir rejeição no transplante cardíaco. | 98.3%        | <div><div></div>Aprovado</div> |

## Resumo por Modelo

| Modelo                            | Similaridade Média | Taxa de Aprovação | Tempo Médio | Bloqueados | Falhas |
|-----------------------------------|--------------------|-------------------|-------------|------------|--------|
| Llama-3.2-3B-Instruct-q4f16_1-MLC | 98.3%              | 100%              | 2,040ms     | 0          | 0      |

## Perguntas de teste

Qual a finalidade do Tacrolimo?

A finalidade do Tacrolimo é prevenir rejeição no transpl.

+ Adicionar pergunta

Executar Benchmark

## Resultados

Exportar CSV

| Modelo                            | Pergunta                             | Resposta Gerada                                                        | Similaridade | Veredito                       |
|-----------------------------------|--------------------------------------|------------------------------------------------------------------------|--------------|--------------------------------|
| Llama-3.2-3B-Instruct-q4f16_1-MLC | ad588457-4607-4284-9588-156d6021e7e4 | A finalidade do Tacrolimo é prevenir rejeição no transplante cardíaco. | 98.3%        | <div><div></div>Aprovado</div> |
| Phi-3.5-mini-instruct-q4f16_1-MLC | ad588457-4607-4284-9588-156d6021e7e4 | Imunossupressor para prevenir a rejeição do transplante cardíaco.      | 89.8%        | <div><div></div>Aprovado</div> |

## Resumo por Modelo

| Modelo                            | Similaridade Média | Taxa de Aprovação | Tempo Médio | Bloqueados | Falhas |
|-----------------------------------|--------------------|-------------------|-------------|------------|--------|
| Llama-3.2-3B-Instruct-q4f16_1-MLC | 98.3%              | 100%              | 2,040ms     | 0          | 0      |
| Phi-3.5-mini-instruct-q4f16_1-MLC | 89.8%              | 100%              | 2,690ms     | 0          | 0      |

# Obrigado!

---

Nikolas Lacerda Santos